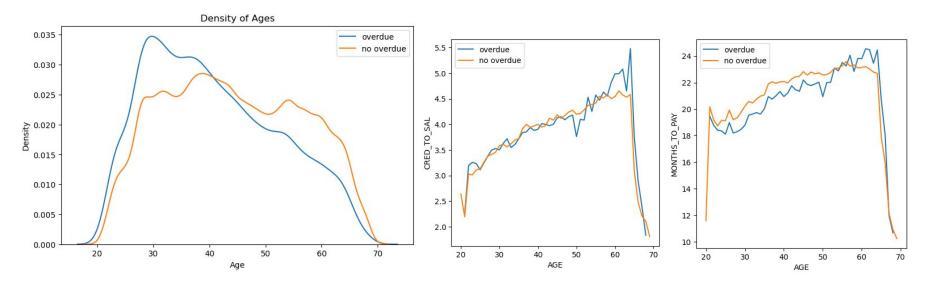


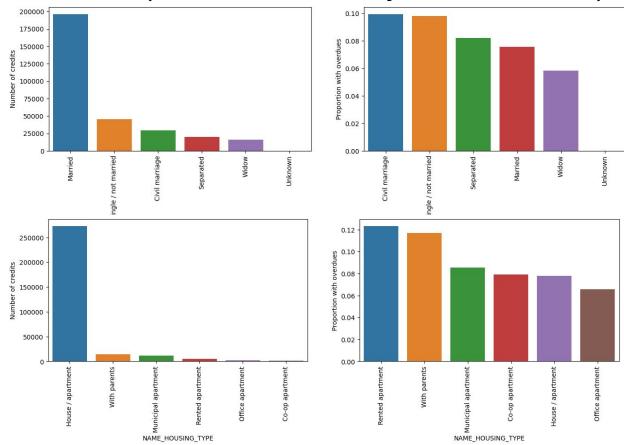
Предварительный анализ (возраст)

- Как можно увидеть, среди молодых людей чаще встречается просрочка по кредиту
- На втором графике представлено отношение размера кредита к зарплате. Можно заметить всплеск в районе 65 лет.
- Такой же всплеск и для количества месяцев на выплату кредита. Это может быть связано с преклонным возрастом и риском внезапной смерти кредитора.



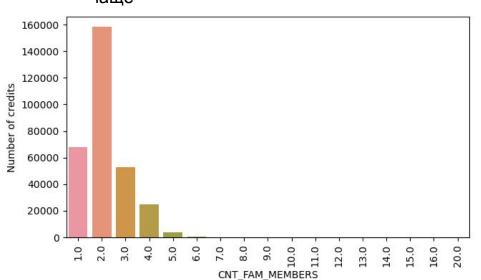
Предварительный анализ(семейный статус, тип жилья)

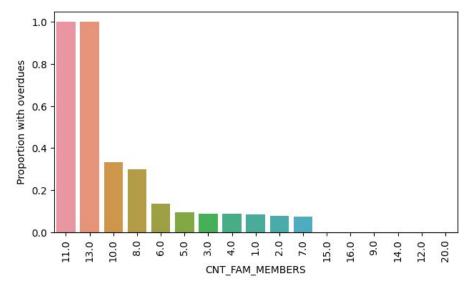
- Вдовы берут меньше кредитов, чем остальные группы, но при этом просрочивают на уровне других групп
- Люди, которые живут в со-ор берут меньше всего кредитов, но при этом просрочивают их на таком же уровне



Предварительный анализ (размер семьи)

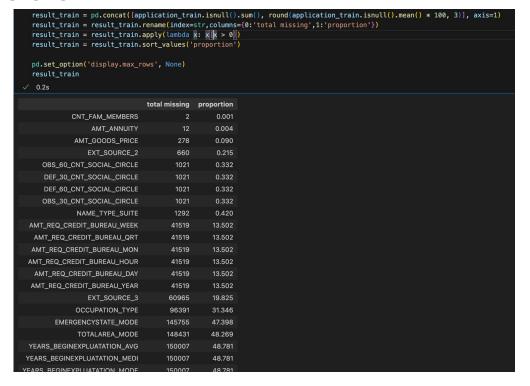
 Люди с большими семьями берут мало кредитов, но при этом просрочивают выплаты по ним чаще





Обработка application_train / application_test / bureau

Поиск None значений:



Работа с категориальными фичами

```
pd.set_option('display.max_rows', None)
   for column in application_train.select_dtypes(include='object').columns:
       print(column, " ", application_train[column].unique(), "\n")
NAME CONTRACT TYPE ['Cash loans' 'Revolving loans']
CODE GENDER ['M' 'F' 'XNA']
FLAG OWN CAR ['N' 'Y']
FLAG OWN REALTY ['Y' 'N']
NAME_TYPE_SUITE ['Unaccompanied' 'Family' 'Spouse, partner' 'Children' 'Other_A' nan
 'Other_B' 'Group of people']
NAME_INCOME_TYPE ['Working' 'State servant' 'Commercial associate' 'Pensioner' 'Unemployed'
 'Student' 'Businessman' 'Maternity leave']
NAME_EDUCATION_TYPE ['Secondary / secondary special' 'Higher education' 'Incomplete higher'
 'Lower secondary' 'Academic degree']
NAME_FAMILY_STATUS ['Single / not married' 'Married' 'Civil marriage' 'Widow' 'Separated'
 'Unknown'l
NAME_HOUSING_TYPE ['House / apartment' 'Rented apartment' 'With parents'
 'Municipal apartment' 'Office apartment' 'Co-op apartment']
OCCUPATION_TYPE ['Laborers' 'Core staff' 'Accountants' 'Managers' nan 'Drivers'
 'Sales staff' 'Cleaning staff' 'Cooking staff' 'Private service staff'
 'Trade: type 1' 'Industry: type 5' 'Industry: type 10' 'Legal Services'
 'Advertising' 'Trade: type 5' 'Cleaning' 'Industry: type 13'
 'Trade: type 4' 'Telecom' 'Industry: type 8' 'Realtor' 'Industry: type 6']
```

✓ 0.3s

```
application_train['NAME_CONTRACT_TYPE'] = application_train['NAME_CONTRACT_TYPE'].apply(lambda x: int(1) if x == 'Y' else int(0))
application_train['FLAG_OWN_CAR'] = application_train['FLAG_OWN_CAR'].apply(lambda x: int(1) if x == 'Y' else int(0))
application_train['FLAG_OWN_REALTY'] = application_train['FLAG_OWN_REALTY'].apply(lambda x: int(1) if x == 'Y' else int(0))
application_train['CODE_GENDER'] = application_train['CODE_GENDER'].apply(lambda x: int(1) if x == 'M' else (int(0) if x == 'F' else int(np.random.ran
application_test['NAME_CONTRACT_TYPE'] = application_test['NAME_CONTRACT_TYPE'].apply(lambda x: int(1) if x == 'Y' else int(0))
application_test['FLAG_OWN_CAR'] = application_test['FLAG_OWN_CAR'].apply(lambda x: int(1) if x == 'Y' else int(0))
application_test['FLAG_OWN_REALTY'] = application_test['FLAG_OWN_REALTY'].apply(lambda x: int(1) if x == 'Y' else int(0))
application_test['CODE_GENDER'] = application_test['CODE_GENDER'].apply(lambda x: int(1) if x == 'M' else (int(0) if x == 'F' else int(np.random.randi
```

mean_target_encoding

```
def add_noise(series, noise_level):
      return series * (1 + noise_level * np.random.randn(len(series)))
  def target_encode(trn_series=None,
                   tst_series=None,
                   target=None,
                   min samples leaf=1.
                   smoothing=1,
                   noise_level=0):
      Smoothing is computed like in the following paper by Daniele Micci-Barreca
      https://kaggle2.blob.core.windows.net/forum-message-attachments/225952/7441/high%20cardinality%20categoricals.pdf
      trn_series : training categorical feature as a pd.Series
      tst series : test categorical feature as a pd.Series
      target : target data as a pd.Series
      min_samples_leaf (int): minimum samples to take category average into account
      smoothing (int): smoothing effect to balance categorical average vs prior
      assert len(trn series) == len(target)
      assert trn_series.name == tst_series.name
      temp = pd.concat([trn_series, target], axis=1)
      # Compute target mean
      averages = temp.groupby(by=trn_series.name)[target.name].agg(["mean", "count"])
      # Compute smoothing
      smoothing = 1 / (1 + np.exp(-(averages["count"] - min_samples_leaf) / smoothing))
      # Apply average function to all target data
      prior = target.mean()
      # The bigger the count the less full_avg is taken into account
     averages[target.name] = prior * (1 - smoothing) + averages["mean"] * smoothing
      averages.drop(["mean", "count"], axis=1, inplace=True)
      # Apply averages to trn and tst series
      ft_trn_series = pd.merge(
         trn series.to frame(trn series.name).
         averages.reset_index().rename(columns={'index': target.name, target.name: 'average'}),
         on=trn_series.name,
         how='left')['average'].rename(trn_series.name + '_mean').fillna(prior)
      # pd.merge does not keep the index so restore it
      ft_trn_series.index = trn_series.index
      ft_tst_series = pd.merge(
         tst_series.to_frame(tst_series.name),
         averages.reset index().rename(columns={'index': target.name, target.name: 'average'}),
         on=tst_series.name,
         how='left')['average'].rename(trn_series.name + '_mean').fillna(prior)
      # pd.merge does not keep the index so restore it
      ft tst series.index = tst series.index
      return add_noise(ft_trn_series, noise_level), add_noise(ft_tst_series, noise_level)
✓ 0.0s
```

Заполним None средним

DEF_60_CNT_SOCIAL_CIRCLE

AMT_REQ_CREDIT_BUREAU_HOUR
AMT_REQ_CREDIT_BUREAU_DAY

AMT REQ CREDIT BUREAU WEEK

AMT_REQ_CREDIT_BUREAU_MON

AMT_REQ_CREDIT_BUREAU_QRT

AMT_REQ_CREDIT_BUREAU_YEAR

EXT_SOURCE_3

```
result_train = pd.concat([application_train.isnull().sum(), round(application_train.isnull().mean() * 100, 3)], axis=1)
  result_train = result_train.rename(index=str,columns={0:'total missing',1:'proportion'})
  result train = result train.apply(lambda x: x[x > 0])
  result_train = result_train.sort_values('proportion')
  pd.set_option('display.max_rows', None)
  result_train
✓ 0.0s
                              total missing
                                           proportion
                                        2
                                                0.001
           CNT_FAM_MEMBERS
                AMT_ANNUITY
                                       12
                                                0.004
           AMT_GOODS_PRICE
                                      278
                                                0.090
               EXT_SOURCE_2
                                      660
                                                0.215
   OBS_30_CNT_SOCIAL_CIRCLE
                                     1021
                                                0.332
   DEF_30_CNT_SOCIAL_CIRCLE
                                     1021
                                                0.332
   OBS_60_CNT_SOCIAL_CIRCLE
                                     1021
                                                0.332
```

0.332

13.502

13.502

13.502 13.502

13.502 13.502

19.825

1021 41519

41519

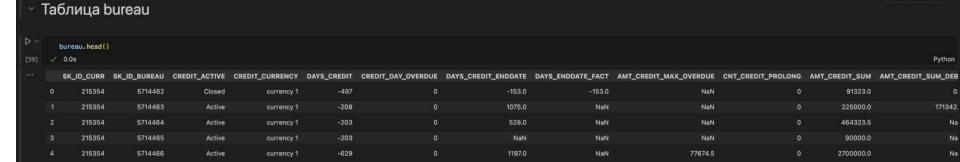
41519

41519

41519

41519

60965



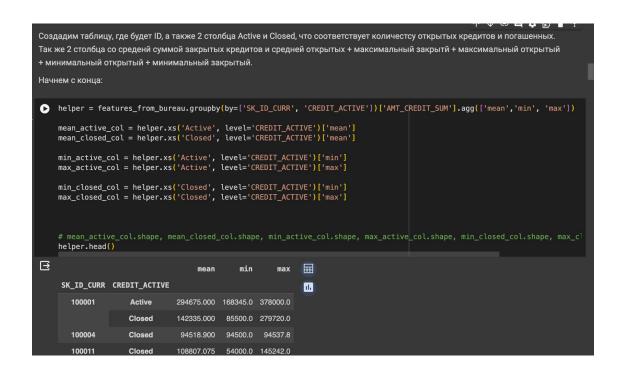
Python

bureau shape

[60] V 0.0s

... (1716428, 17)

Фичи (bureau) -> добавляем в train и test (aplication)

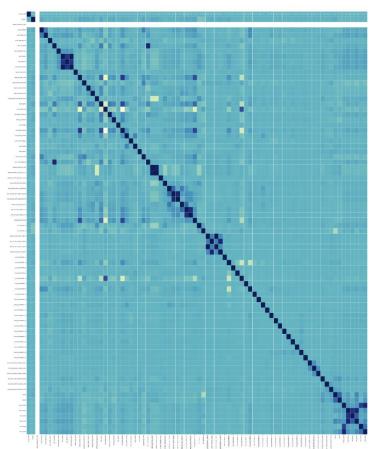


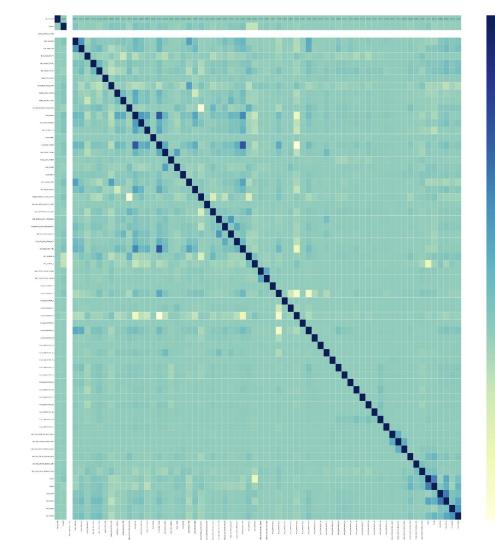
Фичи (bureau) -> добавляем в train и test (aplication)

```
test = pd.merge(mean_closed_col, mean_active_col, on='SK_ID_CURR', how='left')
    test = pd.merge(test, min_active_col , on='SK_ID_CURR', how='left')
    test = pd.merge(test, max active col , on='SK ID CURR', how='left')
    test = pd.merge(test, min_closed_col , on='SK_ID_CURR', how='left')
    test = pd.merge(test, max_closed_col , on='SK_ID_CURR', how='left')
    rename_dict = {'mean_x': 'mean_Closed', 'mean_y':'mean_Active',
                    'min x': 'min Active', 'max x': 'max Active',
                    'min_y': 'min_Closed', 'max_y': 'max_Closed',
    test = test.rename(columns=rename dict)
    test = test.fillna(0)
    test.head()
•
                mean Closed mean Active min Active max Active min Closed max Closed
     SK_ID_CURR
       100001
                     142335.0
                              294675.0000
                                            168345.000
                                                          378000.0
                                                                       85500.0
                                                                                  279720.0
       100002
                                                          450000.0
                                                                                  135000.0
                               240994.2825
                                             31988.565
                                                                          0.0
       100003
                      69133.5
                              810000.0000
                                           810000.000
                                                          810000.0
                                                                      22248.0
                                                                                  112500.0
       100004
                      94518.9
                                    0.0000
                                                 0.000
                                                                      94500.0
                                                                                  94537.8
       100005
                      58500.0
                              299313.0000
                                             29826.000
                                                          568800.0
                                                                       58500.0
                                                                                   58500.0
```

Обработка корреляции

```
Обработка корреляции
                                                                                                                             corrmat = application_train.corr()
    fig, ax = plt.subplots()
    fig.set_size_inches(70, 70)
    sns.heatmap(corrmat, cmap="YlGnBu", linewidths=.5, annot=True)
    corr_matrix = application_train.corr().abs()
    # порог корреляции
    threshold = 0.7
    # создание маски для отбрасывания коррелирующих признаков
    mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
    corr_matrix_masked = corr_matrix.mask(mask)
    # отброс признаков с модулем корреляции больше порога
    to_drop = [column for column in corr_matrix_masked.columns if any(corr_matrix_masked[column] > threshold)]
    application_train = application_train.drop(to_drop, axis=1)
```





Фичи (installments_payments)

```
ins['NEW DAYS PAID EARLIER'] = ins['DAYS INSTALMENT']-ins['DAYS ENTRY PAYMENT']
                                                                                           ↑ ↓ ⊕ ■ ☆ □
ins['NEW NUM PAID LATER'] = ins['NEW DAYS PAID EARLIER'].map(lambda x: 1 if x<0 else 0)
agg list = {'NUM INSTALMENT VERSION':['nunique'],
           'NUM_INSTALMENT_NUMBER': 'max',
           'DAYS INSTALMENT':['min','max'],
           'DAYS_ENTRY_PAYMENT':['min','max'],
           'AMT_INSTALMENT':['min','max','sum','mean'],
           'AMT_PAYMENT':['min','max','sum','mean'],
           'NEW DAYS_PAID_EARLIER': 'mean',
           'NEW NUM PAID LATER': 'sum'}
ins_agg = ins.groupby('SK_ID_PREV').agg(agg_list)
ins_agg.columns = pd.Index(("INS_" + e[0] + '_' + e[1].upper() for e in ins_agg.columns.tolist()])
ins_agg.drop(['INS_DAYS_INSTALMENT_MIN',
               'INS DAYS INSTALMENT MAX',
               'INS_DAYS_ENTRY_PAYMENT_MIN',
               'INS DAYS ENTRY PAYMENT MAX'],axis=1,inplace=True)
ins_agg['INS_NEW_PAYMENT_PERC'] = ins_agg['INS_AMT_PAYMENT_SUM'] / ins_agg['INS_AMT_INSTALMENT_SUM']
ins_agg['INS_NEW_PAYMENT_DIFF'] = ins_agg['INS_AMT_INSTALMENT_SUM'] - ins_agg['INS_AMT_PAYMENT_SUM']
agg_list_previous_application = {}
for col in ins agg.columns:
    agg_list_previous_application[col] = ['mean', "min", "max", "sum"]
ins_agg.reset_index(inplace = True)
return agg_list_previous_application, ins_agg
```

- installments_payments.csv содержит историю выплат по ранее выданным кредитам в Home Credit
- NEW_DAYS_PAID_EARLIER показывает, насколько раньше был сделан платеж.
- NEW_NUM_PAID_LATER 1, если платеж был сделан позже, и 0 иначе.
- Фичи агрегируются по SK_ID_PREV с по 'nunique', 'max', 'min', 'sum', 'mean'.
- Удаляется лишнее
- INS_NEW_PAYMENT_PERC отношение суммы платежей к сумме взносов
- INS_NEW_PAYMENT_DIFF разница между суммой взносов и суммой платежей.

Фичи (POS_CASH_balance)

```
pos = pd.get_dummies(pos, columns=['NAME_CONTRACT_STATUS'], dummy_na = True)
agg list = {'MONTHS BALANCE':['min','max'].
                                        'CNT_INSTALMENT':['min','max'],
                                        'CNT_INSTALMENT_FUTURE':['min','max'],
                                        'SK_DPD':['max','mean'],
                                        'SK DPD DEF':['max','mean'].
                                        'NAME_CONTRACT_STATUS_Active':'sum',
                                        'NAME_CONTRACT_STATUS_Amortized debt':'sum',
                                        'NAME CONTRACT STATUS Approved': 'sum',
                                        'NAME_CONTRACT_STATUS_Canceled': 'sum',
                                        'NAME_CONTRACT_STATUS_Completed':'sum',
                                        'NAME CONTRACT STATUS Returned to the store': 'sum',
                                        'NAME CONTRACT STATUS Signed': 'sum'.
                                        'NAME CONTRACT STATUS XNA': 'sum'.
                                        'NAME_CONTRACT_STATUS_nan':'sum'
pos_agg = pos.groupby('SK_ID_PREV').agg(agg_list)
pos_agg.columns= pd.Index(["POS_" + e[0] + '_' + e[1].upper() for e in pos_agg.columns.tolist()])
pos_agg['POS_NEW_IS_CREDIT_NOT_COMPLETED_ON_TIME']= (pos_agg['POS_CNT_INSTALMENT_FUTURE_MIN']==0) & (pos_agg['POS_NAME_CONTRACT_STATUS_Completed_SUM']
pos_agg['POS_NEW_IS_CREDIT_NOT_COMPLETED_ON_TIME']=pos_agg['POS_NEW_IS_CREDIT_NOT_COMPLETED_ON_TIME'].astype(int)
pos_agg.drop(['POS_NAME_CONTRACT_STATUS_Approved_SUM',
               'POS NAME CONTRACT STATUS Amortized debt SUM'.
               'POS_NAME_CONTRACT_STATUS_Canceled_SUM',
               'POS_NAME_CONTRACT_STATUS_Returned to the store_SUM',
               'POS NAME CONTRACT STATUS Signed SUM',
```

- POS_CASH_balance.csv содержит месячные снепшоты баланса предыдущих POS (оплат) и наличных кредитов, которые заявитель имел с Home Credit.
- Фичи агрегируются по SK_ID_PREV по 'max', 'min', 'sum', 'mean'.
- POS_NEW_IS_CREDIT_NOT_COMPLETE
 D_ON_TIME указывает, был ли
 кредит завершен вовремя.
- Удаляется лишнее

Фичи (previous_application)

```
def previous_application(agg_list_previous_application):
   df prev = pd.read csv('previous application.csv')
   df_prev["WEEKDAY_APPR_PROCESS_START"] = df_prev["WEEKDAY_APPR_PROCESS_START"].replace(['MONDAY','TUESDAY', 'WEDNESDAY','THURSDAY','FRIDAY'], 'WEEK_DAY
   df_prev["WEEKDAY_APPR_PROCESS_START"] = df_prev["WEEKDAY_APPR_PROCESS_START"]. replace(['SATURDAY', 'SUNDAY'], 'WEEKEND')
   a = [8,9,10,11,12,13,14,15,16,17]
   df_prev["HOUR_APPR_PROCESS_START"] = df_prev["HOUR_APPR_PROCESS_START"].replace(a, 'working_hours')
   b = [18,19,20,21,22,23,0,1,2,3,4,5,6,7]
   df_prev["HOUR_APPR_PROCESS_START"] = df_prev["HOUR_APPR_PROCESS_START"].replace(b, 'off_hours')
   df_prev["DAYS_DECISION"] = [1 if abs(i/(12*30)) <=1 else 0 for i in df_prev.DAYS_DECISION]</pre>
   df_prev["NAME_TYPE_SUITE"] = df_prev["NAME_TYPE_SUITE"].replace('Unaccompanied', 'alone')
   b = ['Family', 'Spouse, partner', 'Children', 'Other_B', 'Other_A', 'Group of people']
   df_prev["NAME_TYPE_SUITE"] = df_prev["NAME_TYPE_SUITE"].replace(b, 'not_alone')
   a = ['Auto Accessories', 'Jewelry', 'Homewares', 'Medical Supplies', 'Vehicles', 'Sport and Leisure',
         'Gardening', 'Other', 'Office Appliances', 'Tourism', 'Medicine', 'Direct Sales', 'Fitness', 'Additional Service',
         'Education', 'Weapon', 'Insurance', 'House Construction', 'Animals']
   df prev["NAME GOODS CATEGORY"] = df prev["NAME GOODS CATEGORY"].replace(a, 'others')
   a = ['Auto technology', 'Jewelry', 'MLM partners', 'Tourism']
   df prev["NAME SELLER INDUSTRY"] = df prev["NAME SELLER INDUSTRY"].replace(a, 'others')
   df prev["LOAN RATE"] = df prev.AMT APPLICATION/df prev.AMT CREDIT
```

- previous_application.csv содержит предыдущие заявки на кредиты.
- Дни недели, когда была начата процедура одобрения, группируются на рабочие /выходные + часы на рабочие/нерабочие.
- DAYS_DECISION равен 1, если решение было принято в течение последнего года, и 0 в противном случае.
- Признаки NAME_TYPE_SUITE,
 NAME_GOODS_CATEGORY,
 NAME_SELLER_INDUSTRY упрощаются
- новый LOAN_RATE отношение суммы заявки к сумме кредита
- NEW_INSURANCE равен 1, если разница больше 0 (что указывает на наличие страховки), и 0, если разница меньше или равна 0. Если данные отсутствуют, устанавливается пр.пап. Разница между суммой кредита (AMT_CREDIT) и стоимостью товара (AMT_GOODS_PRICE)
- Фичи агрегируются по SK_ID_CURR по 'max', 'min', 'sum', 'mean'.

Далее они мержатся по SK_ID_CURR + отсечение по порогу корреляции

Модель

Рассматривался бустинг, в том числе CatBoost, Lightgbm, XGBoost

Перебирались следующие параметры:

- 1. learning rate
- 2. n_iterations
- 3. параметр регуляризации 12







Модель

В итоге используем CatBoostClassifier на 10 тыс итераций

Причины выбора:

- Легко собрать и запустить на GPU
- Много туториалов
- Качество у всех бустингов сравнимое

Submission and Description		Private Score (1)	Public Score (i)	Selected
€	res11.csv Complete (after deadline) · 13h ago	0.73254	0.73733	
©	res10.csv Complete (after deadline) · 13h ago	0.7326	0.73749	
€	res9.csv Complete (after deadline) · 13h ago	0.76337	0.76584	
€ ©	res8.csv Complete (after deadline) · 2d ago	0.76455	0.76628	